ПРОЕКТ ПО БАЗАМ ДАННЫХ

Аналитика каталога Spotify

Как нецензурная лирика влияет на популярность трека в разных жанрах

Что мы хотели узнать

ГЛАВНЫЙ ВОПРОС / EXPLICIT-ЭФФЕКТ

Как explicit влияет на популярность трека в разных жанрах?

2 В каких жанрах больше всего explicit-треков?

3 Отличается ли у них длительность?

Как мы делили работу

Продукт-менеджер: **Юровских Михаил**

Участники	Что делал
Юровских Михаил	Придумывал тему, Организовывал работу, распределял задачи «Давал по жопе всем, в чате», Искал норм модели ИИ для работы «к сожалению не нашёл:(» Писал стикеры на фрейме, писал часть кода sql.
Шубин Сергей	Анализировал все стикеры , работал в команде, слушался продукт-менеджера, Работал над паспортом проекта, Написал sql запрос, придумывал идею для аналитического вопроса, работал над вне аудиторками «даже пришлось иди к продукт-менеджеру в офис».
Ионов Кирилл	Работал паспорта проекта, писал sql запрос, делал презентацию, анализировал все стикеры «понял все».
Земцов Дмитрий	Excel-отчёт, Er-схему, поддерживал дух команды, не давал свернуть команде в другое русло «запрещал играть в яндекс игры».

Откуда данные

Kaggle / Spotify Tracks Dataset

114 тыс.

треков, 125 жанров



Наша выборка / spotify_mini.sql

1 500

хитов с популярностью 75+, 66 жанров

Риск 1

Нет данных о пользователях: видим только метрику popularity, а не прослушивания

Риск 2

Сложная нормализация: много связей «многие-ко-многим», фиты исполнителей

Аудит данных: две улики

Улика 1 / пропуски

NULL во всех 6 таблицах: **0**

Пустые строки и пробелы: **0**

N/A, None, Unknown: **0**

Исключение: explicit = 0 — это значения, а не пропуски

Улика 2 / дубли и странности

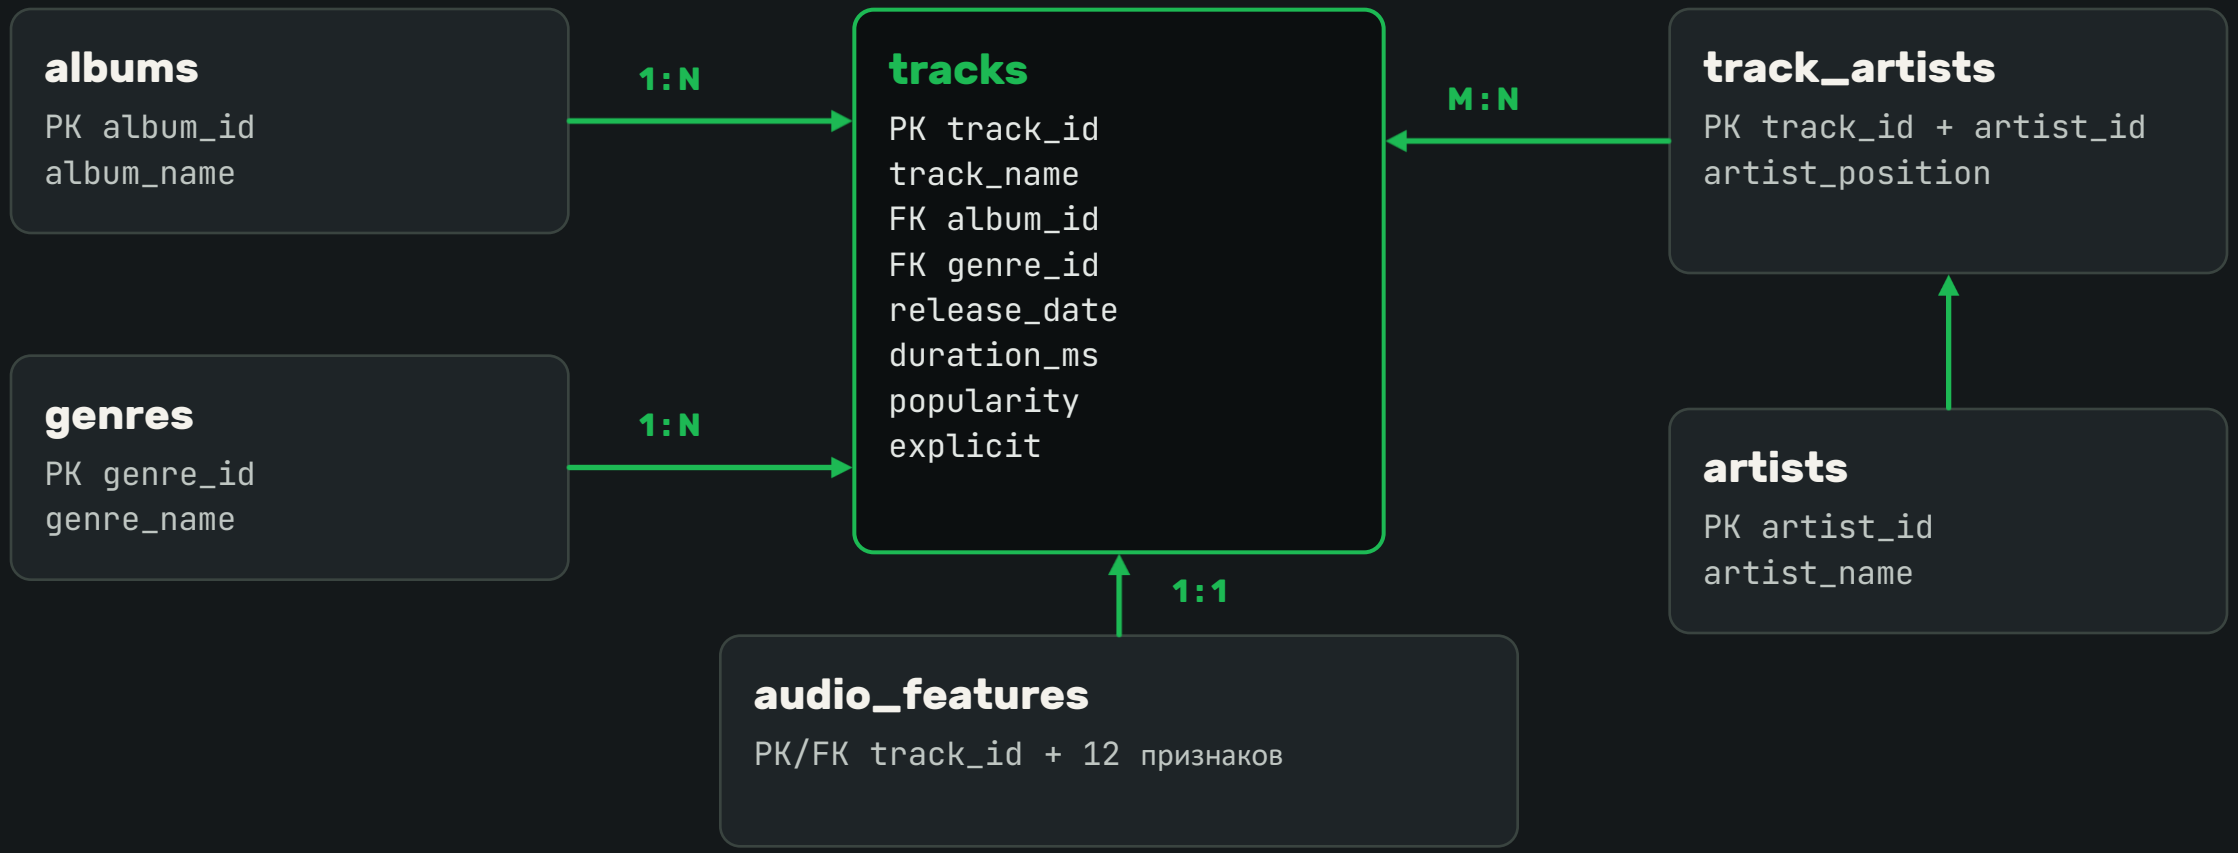
60 повторяющихся названий треков (122 записи)

2 трека с tempo = 0 (белый шум)

Даты 1960–2024, но As It Was — 1985 год

Дублей по ID нет.

Разложили одну таблицу на шесть



Собрали базу и проверили связи

Ограничения, которые ловят ошибки сразу при вставке

```
popularity INTEGER NOT NULL
  CHECK (popularity BETWEEN 0 AND 100)

FOREIGN KEY (artist_id)
  REFERENCES artists(artist_id)
  ON DELETE RESTRICT
```

После загрузки

треков	1 500
исполнителей	992
альбомов	1 249
связей трек–артист	2 089

foreign_key_check: 0 ошибок

Запрос 1: жанр и пометка explicit

```
SELECT
 genres.genre_name AS genre,
 tracks.explicit,
 COUNT(tracks.track_id) AS tracks_count,
 ROUND(AVG(tracks.popularity), 2) AS avg_popularity,
 MIN(tracks.popularity) AS min_popularity,
 MAX(tracks.popularity) AS max_popularity
FROM tracks
INNER JOIN genres ON tracks.genre_id = genres.genre_id
GROUP BY
 genres.genre_name,
 tracks.explicit;
```

Что он даёт

Для каждого жанра: сколько треков и какая средняя популярность, отдельно с explicit и без

99 строк, которые ушли в Excel

Explicit-эффект есть, но небольшой

обычные • 1 167 треков

79,3

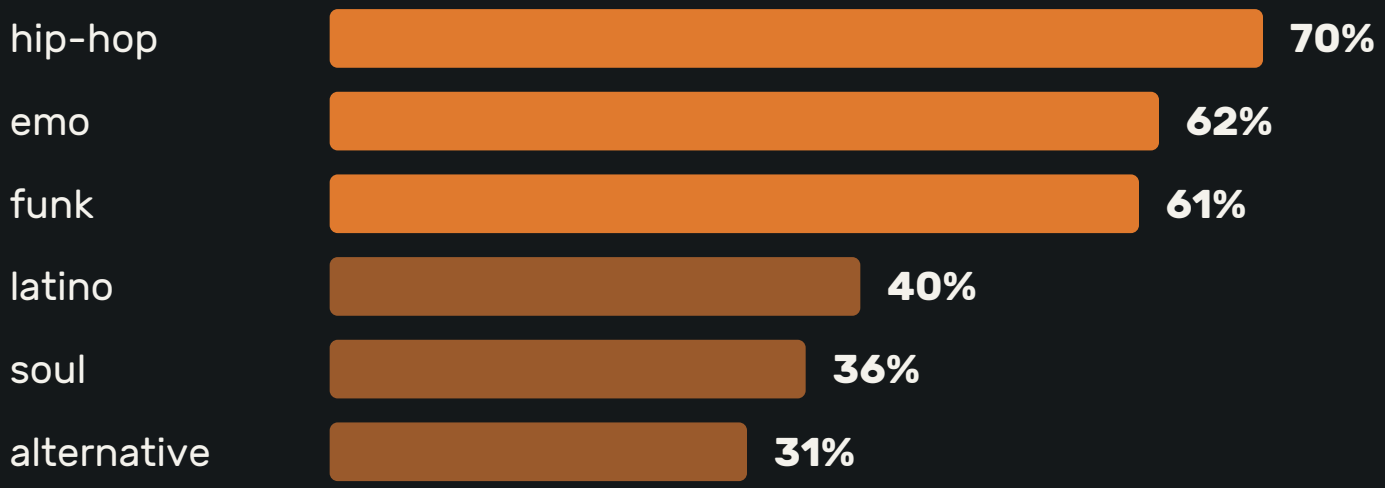
explicit • 333 трека

80,5

средняя популярность из 100

Сильнее всего в хип-хопе: 80,2 против 83,1

Где explicit — норма



0%

country, folk, piano

ни одного explicit-трека

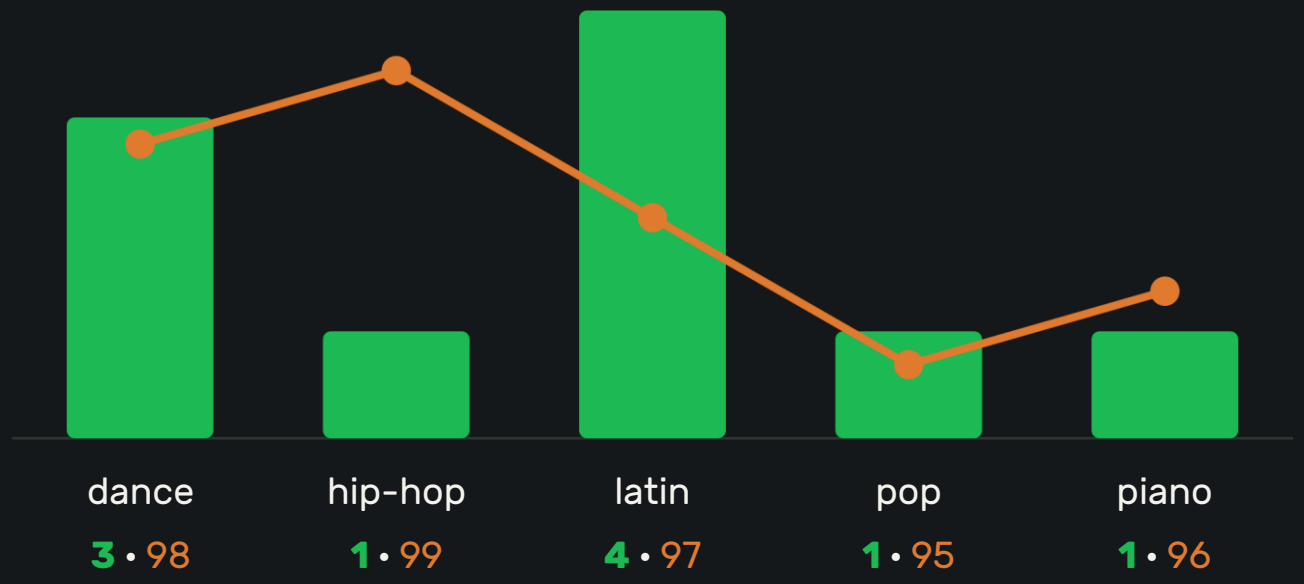
Запрос 2: кто наверху рейтинга

```
SELECT tracks.track_name,
 artists.artist_name,
 genres.genre_name,
 tracks.popularity,
 tracks.explicit
FROM tracks
JOIN genres ON genres.genre_id = tracks.genre_id
JOIN track_artists ON track_artists.track_id =
tracks.track_id
JOIN artists ON artists.artist_id =
track_artists.artist_id
GROUP BY tracks.track_id, tracks.track_name,
genres.genre_name, tracks.popularity, tracks.explicit
ORDER BY tracks.popularity DESC, tracks.track_name
LIMIT 10;
```

Unholy / Sam Smith	**100**
Bzrp Session 52 / Quevedo	**99**
La Bachata / Manuel Turizo	**98**
I'm Good / David Guetta	**98**
Me Porto Bonito / Bad Bunny	**97**

Bad Bunny: 3 трека в топ-10 и 54 в выборке

Excel: жанры в топ-10 треков



Чаще всего в топе **latin** (4 трека) и **dance** (3)

Выше всех средний балл у **hip-hop**: 99, но это один трек

Bad Bunny занял 3 места из 10 и смещает картину

Что в итоге

Ответы

1. Explicit-эффект есть, но небольшой
2. Больше всего explicit в hip-hop (70%) и emo (62%), нет в country и folk
3. Explicit-треки в среднем на 9 секунд короче, но это зависит от жанра

Спасибо! Готовы ответить на вопросы